

Discussion de paper: Argyle et al. (2023)

Out of One, Many. Using Language Models to Simulate Human Samples

Curso 1INT46. Bloque VII. Semana 14

Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). *Out of one, many: Using language models to simulate human samples.* **Political Analysis, 31(3), 337-351.**

Uno de los primeros papers publicados en una revista top de ciencia politica que evalua sistematicamente si los LLMs pueden reproducir patrones de respuesta de subgrupos demograficos.

Pregunta central

¿Pueden los LLMs, condicionados en descripciones demográficas, generar distribuciones de respuestas que reflejen las de subgrupos humanos reales en encuestas?

El paper responde con un experimento cuidadoso: comparan respuestas simuladas por GPT-3 (via el metodo de “silicon samples”) con datos reales de encuestas.

Metodo: silicon samples

El procedimiento:

- 1 Toman una encuesta real (ANES en EEUU).
- 2 Extraen las variables demograficas de cada respondiente.
- 3 Construyen un prompt que describe a esa persona.
- 4 Piden a GPT-3 que responda las mismas preguntas de la encuesta.
- 5 Comparan las distribuciones de respuestas simuladas vs reales.

Repiten esto para varios items sensibles: opinion politica, actitudes hacia grupos, votos.

El paper propone el concepto de **algorithmic fidelity**: en que medida un LLM condicionado en demograficos reproduce fielmente la distribucion de respuestas humanas de ese subgrupo.

Cuatro criterios de fidelidad:

- 1 **Social science coherence**: las respuestas simuladas son internamente consistentes.
- 2 **Consistency**: distintas “personas” del mismo grupo dan patrones similares.
- 3 **Pattern correspondence**: los patrones cruzados demografico $\times$ actitud coinciden con los datos reales.
- 4 **Forward reasoning**: las respuestas anticipan patrones observados en decisiones politicas reales.

Resultados principales

Con GPT-3 aplicado sobre respondientes del ANES:

- Los patrones agregados de respuesta se reproducen razonablemente bien.
- Las correlaciones entre demograficos y actitudes se mantienen en la direccion esperada.
- El grado de fidelidad varia por subgrupo: mejor en los grupos mas frecuentes en el corpus de entrenamiento, peor en grupos menos representados.

Implicaciones optimistas del paper

Los autores argumentan que los LLMs pueden servir como:

- Herramienta de pretesteo de instrumentos.
- Fuente de hipótesis exploratorias en poblaciones difíciles de acceder.
- Prior informativo para diseño experimental bayesiano.
- Estudio piloto barato antes de campos grandes.

Y sugieren aplicaciones en áreas donde el sesgo de deseabilidad social es alto.

Limitaciones reconocidas

El paper es honesto sobre las limitaciones:

- Los LLMs reproducen patrones aprendidos, no razonamiento genuino.
- Los subgrupos poco representados en los datos de entrenamiento se simulan peor.
- Las respuestas dependen sensiblemente del prompt (framing effects).
- No se puede validar externamente sin datos humanos comparables.

Desde 2023 la literatura ha extendido y cuestionado estos hallazgos en varias direcciones:

- Replicas con modelos posteriores (GPT-4, Claude, Llama) que muestran resultados mixtos segun el modelo y el grupo.
- Evidencia de que los LLMs tienden a homogeneizar respuestas dentro de un mismo subgrupo, subestimando la varianza real.
- Discusion sobre si las respuestas simuladas refuerzan estereotipos demograficos.
- Trabajos que exploran usos hibridos (LLM + validacion humana).

Consideraciones para America Latina:

- Los LLMs se entrenan mayoritariamente con texto en ingles.
- Los patrones politicos peruanos (fujimorismo, izquierda democratica, etc.) no estan bien representados.
- Hay poco corpus autoctono sobre actitudes de zonas rurales o comunidades indigenas.
- Usar LLMs para simular respondientes peruanos es especialmente riesgoso.

Recomendacion practica: usar como herramienta de exploracion, no como sustituto de datos.

Comparacion con el pretesteo tradicional

Metodo	Costo	Validez
Piloto de 30-50 personas	Alto	Alta
Think-aloud con 5-10 personas	Medio	Muy alta (cualitativa)
Silicon samples LLM	Muy bajo	Media, con sesgos
Focus group	Medio	Alta (cualitativa)

Los silicon samples no sustituyen ninguno de los otros; complementan al pretesteo tradicional cuando el presupuesto o el tiempo son restrictivos.

Preguntas para la discusion

- ❶ ?Como validarias el uso de un LLM en un contexto peruano?
- ❷ ?Es etico presentar respuestas de LLM como si fueran de humanos?
- ❸ ?Los “silicon samples” pueden reemplazar el piloto humano en algunos casos?
- ❹ ?Que pruebas de fidelidad harias antes de aceptar los resultados de un LLM?
- ❺ ?Como se compara con el uso de datos administrativos como prior?

Contribucion mas amplia del paper

Mas alla del hallazgo especifico, el paper abre una linea de investigacion:

- Como usar LLMs en el ciclo de investigacion cuantitativa.
- Como definir estandares de validez para respuestas generadas por IA.
- Como discutir el uso etico y transparente de LLMs.
- Como usar LLMs para acelerar el diseno experimental sin sacrificar rigor.

Es un paper obligatorio para investigadores que consideren usar LLMs en cualquier fase de un estudio de encuesta.

Que NO dice el paper

Es importante no sobre-interpretar:

- NO dice que los LLMs pueden sustituir muestras humanas en produccion.
- NO dice que la fidelidad es uniforme entre grupos.
- NO dice que los LLMs entienden las opiniones que reproducen.
- NO dice que sea etico usar silicon samples sin declararlo explicitamente.

- El diseño experimental sigue siendo el core: los LLMs no cambian eso.
- El pretesteo con humanos es irremplazable en poblaciones no anglosajonas.
- Es responsable declarar cualquier uso de LLM en el reporte.
- El TG2 se debe hacer con datos humanos reales; los LLMs solo se aceptan como herramienta auxiliar.