

Discussion de paper: Bansak, Hainmueller, Hopkins y Yamamoto (2019)

Conjoint Survey Experiments

Curso 1INT46. Bloque VI. Semana 13

Bansak, K., Hainmueller, J., Hopkins, D. J. & Yamamoto, T. (2019). *Conjoint Survey Experiments*. **En Druckman, J. N. & Green, D. P. (Eds.), Cambridge Handbook of Advances in Experimental Political Science.** Cambridge University Press.

Autores en 2019:

- Kirk Bansak: Assistant Professor, UC San Diego.
- Jens Hainmueller: Professor, Stanford.
- Daniel J. Hopkins: Professor, University of Pennsylvania.
- Teppei Yamamoto: Associate Professor, MIT.

Es un **capítulo de libro** (Cambridge Handbook of Advances in Experimental Political Science) que sirve como guía práctica para practitioners de conjoint experiments.

Objetivos del capitulo

Los autores plantean tres objetivos:

- ➊ Introducir el conjoint survey experiment como metodo aplicado.
- ➋ Sintetizar la investigacion reciente que lo emplea y lo mejora.
- ➌ Discutir issues clave que aparecen al usarlo en la practica.

Todo esto usando como ejemplo corrido un experimento propio sobre *candidatos demócratas para enfrentar a Trump en 2020*.

Ejemplo empirico: primarias demócratas 2020

Diseño del experimento:

- Muestra: 503 respondientes en Amazon Mechanical Turk (opt-in, no representativa).
- Tarea: elegir cual candidato demócrata preferirían ver ganar la primaria y enfrentar a Trump.
- Diseño: 15 tablas de comparación por respondiente, cada una con 2 perfiles side-by-side.
- Total: 30 candidatos hipotéticos evaluados por respondiente.
- Aleatorización: independiente entre respondientes, entre tablas y entre atributos.
- Orden de atributos: fijo dentro del respondiente, pero aleatorizado entre respondientes.

Los 10 atributos del candidato hipotetico

- ① **Edad:** 37, 45, 53, 61, 77.
- ② **Genero:** Female, Male.
- ③ **Orientacion sexual:** Straight, Gay.
- ④ **Raza/etnia:** White, Hispanic/Latino, Black, Asian.
- ⑤ **Ocupacion previa:** Business executive, College professor, High school teacher, Lawyer, Doctor, Activist.
- ⑥ **Servicio militar:** Did not serve, Army, Navy, Marine Corps.
- ⑦ **Experiencia politica:** Small-city Mayor, Big-city Mayor, State Legislator, Governor, U.S. Senator, U.S. Representative, No prior political experience.
- ⑧ **Government Healthcare:** All Americans; only older/poor/disabled; those who choose over private plans.
- ⑨ **Pathway to Citizenship:** para menores sin criminal record; para todos sin criminal record; ninguno.
- ⑩ **Cambio climatico:** prohibir fossil fuels; impuestos con reduccion 3 % GDP; solo promover renovables.

Despues de cada tabla se hacen dos preguntas:

- **Rating:** escala 1 a 7. “Como calificarias a cada candidato en enfrentar a Trump?” (1 = definitely NOT want, 7 = definitely want).
- **Forced choice:** elegir el candidato preferido (A o B).
- El orden de estas dos preguntas se aleatoriza por respondiente para detectar efectos de orden.

Dos preguntas sustantivas del experimento

- 1 ?Que atributos aumentan o reducen causalmente el apoyo a un candidato demócrata, promediando sobre los otros atributos? (AMCE)
- 2 ?Los efectos varían por partisan del respondiente (Demócrata, Republicano, Independiente)? (Conditional AMCE)

Los demócratas al elegir su nominado enfrentan un tradeoff entre *electabilidad* y *representatividad política* propia. Los republicanos tienen consideraciones muy distintas.

Ventajas del conjoint en ciencia politica

Los autores identifican varios factores que impulsaron su adopción:

- Mayor atención a inferencia causal via experimental design (Sniderman y Grob 1996).
- Expansión de encuestas administradas por computador que facilitan diseños randomizados.
- Conjoint se ajusta a preguntas centrales de ciencia política: elección de candidatos, actitudes hacia inmigración, vecindarios, paquetes de política.
- Mitigación de *social desirability bias* al variar el atributo sensible junto con otros (Teele, Kalla y Rosenbluth 2018; Horiuchi, Markovich y Yamamoto 2019).

Referencias que los autores citan como evidencia:

- **Hainmueller, Hangartner y Yamamoto (2015)**: conjoint puede replicar votaciones reales de ciudadanía en Suiza.
- **Auerbach y Thachil (2018)**: brokers politicos en slums de India tienen los atributos que residentes reportaron valorar via conjoint.
- **Bansak et al. (2018)**: online respondents pueden completar muchas tareas conjoint antes de que el satisficing degrade la calidad de respuesta.
- **Bansak et al. (2019)**: respondents dan respuestas significativas incluso con muchos atributos.

El capitulo dedica buena parte al diseno experimental:

- Como decidir el numero y tipo de atributos.
- Como definir los niveles (evitar zero cell probability con restricciones).
- Cuantas tareas por respondiente (Bansak et al. 2018 sugiere hasta 30 aceptables).
- Como randomizar (por respondiente, por tabla, por atributo).
- Como manejar orden de atributos (fijo por respondiente, aleatorio entre).

El capitulo explica el analisis en detalle:

- Estimacion del AMCE por OLS simple sobre el long format.
- Errores estandar clusterizados por respondiente.
- Estimacion de *conditional AMCEs* por subgrupo (por partisan, por educacion, etc.).
- Interpretacion en la escala de probabilidad de eleccion o rating.
- Visualizacion recomendada: point estimate + IC 95 % por atributo/nivel.

Los autores identifican varios issues:

- El *choice of reference category* afecta la interpretacion visual del AMCE (Ganter 2021 y otros).
- AMCE promedia sobre la distribucion de niveles del diseno, que puede diferir de la distribucion real.
- Comparar AMCEs entre subgrupos requiere cuidado (Leeper, Hobolt y Tilley 2020).
- Los avances metodologicos recientes (Dafoe, Zhang y Caughey 2018; Acharya, Blackwell y Sen 2018; Egami y Imai 2019) abren nuevas cuestiones.

Diferencias con Hainmueller-Hopkins-Yamamoto (2014)

- El paper de 2014 formaliza matematicamente el AMCE bajo potential outcomes.
- Este capitulo de 2019 es una **guia practica** sobre como implementarlo.
- El 2014 introdujo el estimador; el 2019 sistematiza las lecciones aprendidas en 5 anos de aplicacion.
- El 2014 usa Immigration Experiment y Candidate Experiment del 2012; el 2019 usa un nuevo experimento sobre primarias 2020.
- Juntos son la lectura obligatoria completa para quien va a hacer conjoint en ciencia politica.

Aplicaciones documentadas en el capitulo

Areas donde conjoint se ha aplicado exitosamente en ciencia politica:

- Preferencias por candidatos electorales (Loewen, Rubenson y Spirling 2012).
- Preferencias por inmigrantes (Hainmueller y Hopkins 2015; Bansak, Hainmueller y Hangartner 2016).
- Vecindarios y housing (Hankinson 2018).
- Paquetes de politica publica (Bechtel, Genovese y Scheve 2016).
- Regulacion y trade (Wright, Levy y Citrin 2016).
- Cambio climatico y otras policy areas.

Preguntas para la discusion

- ❶ ?El uso de MTurk (opt-in, no representativa) es una limitacion aceptable para este ejemplo?
- ❷ ?Los 10 atributos del candidato son suficientes o hay dimensiones faltantes clave?
- ❸ ?Como aplicarias este marco a una eleccion peruana hipotetica?
- ❹ ?El AMCE agregado esconde heterogeneidad politica relevante?
- ❺ ?Cual es el limite razonable de tareas por respondiente antes de que fatiga afecte los resultados?

Contextos peruanos donde conjoint es viable:

- Preferencias por candidatos presidenciales o municipales.
- Preferencias por características del sistema pensional (ONP vs AFP).
- Preferencias por atributos de programas sociales (Juntos, Pension 65).
- Preferencias por características de escuelas públicas o privadas.
- Actitudes hacia inmigrantes venezolanos (con atributos como educación, motivo, etc.).
- Preferencias por atributos de seguridad ciudadana.

El TG2 del curso podría adoptar cualquiera de estos como caso.

- El conjoint es una herramienta pragmatica: no requiere modelos estructurales complejos.
- Con 10 o mas atributos, la carga cognitiva es manejable si el diseno es claro.
- Reportar AMCE + conditional AMCE por subgrupo relevante es el estandar.
- El benchmarking con external validity (votaciones reales) es un plus si esta disponible.
- El TG2 puede seguir esta plantilla: definir atributos, aleatorizar, estimar AMCE, comparar por subgrupo.