

Are Emily and Greg more employable than Lakisha and Jamal?

Bertrand y Mullainathan (2004) Discusión de lectura

José Antonio Mendoza Sánchez

Curso 1INT46 Bloque III Facultad de Ciencias Sociales PUCP

Semestre 2026-2

Sobre esta discusión

- Comentamos Bertrand, M. y Mullainathan, S. (2004). *Are Emily and Greg more employable than Lakisha and Jamal? A field experiment on labor market discrimination*. *American Economic Review*, 94(4), 991-1013.
- Paper fundacional del correspondence study moderno.
- Más de 5,000 citas en Google Scholar; está en el top-10 de papers más citados en economía laboral del siglo.
- La lectura del bloque; hoy la discutimos con foco en diseño, estadística, resultados y críticas.

- 1** Contexto y motivación
- 2** Diseño experimental
- 3** Resultados y estadística
- 4** Interpretación
- 5** Críticas y limitaciones
- 6** Qué nos llevamos

Los autores

- **Marianne Bertrand:** en 2004 y hoy en Chicago Booth, NBER y CEPR. Especialista en economía laboral: discriminación, movilidad social, cultura organizacional.
- **Sendhil Mullainathan:** en 2004 en MIT (Department of Economics). Actualmente en Chicago Booth. Trabaja en economía conductual, scarcity, diseño de algoritmos. Co-fundador del programa *ideas42*.
- Combinan agenda empírica rigurosa con implicancias de política pública.

Por qué el paper existió

- Contexto EE.UU. años 2000: legislación anti-discriminatoria en vigor desde los 60s.
- Encuestas mostraban que las empresas negaban discriminar.
- Estudios de audit anteriores (housing audits del HUD) documentaban discriminación con actores humanos pero eran caros y de escala pequeña.
- Faltaba una medición *barata, escalable y creible* del mercado laboral.
- Bertrand y Mullainathan responden con correspondence: envían CVs, no personas.

La contribución central

Aporte del paper

Establecer que la discriminación racial en el mercado laboral de EE.UU. seguía siendo cuantitativamente importante en 2001-2002, con evidencia experimental limpia y a escala.

- Metodológicamente: consolida el correspondence study como método estándar en economía.
- Sustantivamente: cambia la conversación pública sobre discriminación con evidencia *comportamental*.
- Estadísticamente: diseño factorial que permite distinguir efectos por raza y por calidad de CV.

Muestra

- ~ 1,300 avisos de empleo publicados en *Boston Globe* y *Chicago Tribune* entre julio 2001 y mayo 2002.
- Sectores: ventas, servicio administrativo, servicio al cliente.
- Nivel de calificación: puestos entry-level y mid-level.
- Sin muestreo de puestos de alta calificación (limita generalización).
- Total de CVs enviados: aproximadamente 5,000 (4 por aviso).

Diseño factorial 2×2

Cada aviso recibió cuatro CVs:

$$\text{Raza} \in \{\text{blanco, afroamericano}\} \times \text{Calidad} \in \{\text{baja, alta}\}$$

- Se aleatoriza qué CV recibe cuál nombre.
- Calidad se manipula variando educación, experiencia laboral, extras.
- Los CVs se rotan entre avisos para evitar efectos de plantilla específica.

Elección de nombres

- **Ejemplos White** (mencionados en el paper): Emily Walsh, Greg Baker.
- **Ejemplos African-American** (mencionados en el paper): Lakisha Washington, Jamal Jones.
- Apellidos White usados: Baker, Kelly, McCarthy, Murphy, Murray, O'Brien, Ryan, Sullivan, Walsh.
- Apellidos African-American usados: Jackson, Jones, Robinson, Washington, Williams.
- Seleccionados a partir de *birth certificates* de Massachusetts (1974-1979) por frecuencia diferencial entre grupos raciales.
- Validados con encuesta de percepción en Chicago: 30 respondientes clasificaron cada nombre como "White", "African-American", "Other" o "Cannot Tell"; los que no fueron identificados claramente se descartaron.

Componentes del estímulo aleatorizado

- **Nombre:** señal racial principal.
- **Dirección:** barrios plausibles de Boston / Chicago.
- **Teléfono y correo:** reales, manejados por el equipo de investigación.
- **Educación:** high school en CV baja calidad, community college o algo más en alta.
- **Experiencia:** gap ocupacional en baja calidad, promociones y skills específicas en alta.
- Todo lo demás: control estricto.

Aleatorización y balance

- La asignación de nombres a CVs se hace por permutación aleatoria dentro de aviso.
- Cada CV rotaba nombres entre distintas empresas: la misma plantilla base se usaba con Emily en un aviso y con Lakisha en otro.
- Balance de covariables observables entre nombres blancos y afroamericanos: prácticamente idéntico por diseño.
- Test de balance formal reportado en el paper.

Callback rates (Tabla 1 del paper)

Resultados principales del paper:

	Callback rate	n	Ratio
Nombres White	9.65 %	2,435	–
Nombres African-American	6.45 %	2,435	–
Brecha absoluta	3.20 pp	–	–
Brecha relativa	–	–	1.50
<i>p</i> -valor	–	–	0.0000

Interpretación: aplicantes con nombre White necesitan enviar ~ 10 CVs por callback; con nombre African-American, ~ 15 .

Test estadístico

Para $\hat{p}_W = 0,0965$ y $\hat{p}_{AA} = 0,0645$ con $n_W = n_{AA} = 2,435$:

$$z = \frac{0,0965 - 0,0645}{\sqrt{0,0805 \cdot 0,9195 \cdot (2/2435)}} \approx 4,12$$

- $p < 0,0001$: se rechaza $H_0 : p_W = p_{AA}$.
- En regresión con SE clusterizados por aviso (o por empleador y por primer nombre), el efecto se mantiene significativo.
- Efecto grande y preciso por la muestra amplia.

Interacción con calidad del CV

El paper testea si el retorno a la calidad es distinto por raza:

$$Y_i = \alpha + \tau T_i + \gamma Q_i + \delta(T_i \cdot Q_i) + \varepsilon_i$$

Resultados reportados:

- $\hat{\gamma} > 0$: nombres blancos con CV alto reciben más callbacks (retorno positivo a la calidad).
- $\hat{\delta} \approx 0$ o negativo: no hay retorno adicional a la calidad para nombres afroamericanos.
- *"The returns to skill are lower for African-American applicants."*
- Es el hallazgo más inquietante: subir el CV no compensa la discriminación.

Heterogeneidad reportada

El paper explora efectos por:

- **Tipo de industria:** la brecha existe en todos los sectores estudiados. No hay industrias que sean "menos discriminatorias".
- **Tamaño de empresa:** efectos similares entre empresas grandes y pequeñas.
- **Ubicación:** efectos similares entre Boston y Chicago (dos ciudades con demografía distinta).
- **Aviso con lenguaje "equal opportunity employer":** la discriminación está presente incluso ahí.

Robustez amplia; el hallazgo no se disuelve al partir la muestra.

Cluster standard errors

- Cada aviso recibe 4 CVs con nombres distintos: son 4 observaciones no independientes.
- Ignorar el cluster subestima SE y sobreestima significancia.
- Bertrand-Mullainathan clusterizan por aviso.
- La corrección de cluster reduce el t marginalmente pero el efecto sigue siendo significativo.
- Formula del ajuste:

$$\widehat{\text{Var}}_{\text{CR}}(\hat{\theta}) = \frac{G}{G-1} \cdot \frac{N-1}{N-K} \cdot \widehat{\text{Var}}(\hat{\theta})_{\text{cluster}}$$

donde G = número de clusters (avisos), N = número de observaciones.

¿Taste-based o statistical?

- *Discriminación de gusto* (Becker 1957): las firmas obtienen menor utilidad al contratar afroamericanos.
- *Discriminación estadística* (Phelps 1972, Arrow 1973): las firmas usan raza como señal de productividad no observable.
- El diseño factorial de BM aporta al debate: si la brecha fuera estadística, subir la calidad del CV debería reducirla (porque más información suplanta la señal racial). BM encuentran que la brecha *no se reduce* con CV alto.
- Interpretación de los autores: la evidencia es más consistente con discriminación de gusto.
- Pero Heckman (1998) y Neumark (2012) argumentan que no se puede identificar el mecanismo puramente con audit data.

Impacto del paper

- Puso a la discriminación de mercado laboral en el centro de la agenda pública en EE.UU.
- Cientos de replicaciones en otros países (Europa, América Latina, Asia) confirmando el patrón general.
- Motivó políticas como CV anónimos, "ban the box" auditoría de algoritmos de reclutamiento.
- Meta-análisis (Zschirnt y Ruedin 2016, Quillian et al. 2017) muestran que la brecha es sostenida a lo largo de décadas.
- Base metodológica para todos los audits posteriores, incluyendo Galarza-Yamada 2014 en el Perú.

Críticas metodológicas

- **Heckman (1998, JEP)**: la brecha observada mezcla discriminación de gusto y estadística; el audit no las separa.
- **Neumark (2012, JHR)**: la comparación de callback rates es sesgada si $\text{Var}(Z \mid \text{raza})$ difiere entre grupos. Propone modelo estructural.
- **List (2004)**: los actores audit pueden comportarse distinto a solicitantes reales; correspondence lo evita en parte.
- **Crítica clase-raza**: los nombres afroamericanos pueden señalar también clase socioeconómica; los propios autores discuten y descartan parcialmente esta explicación con datos de birth certificates (nota al pie 6 del paper).

Críticas de validez

- **Etapas medida:** solo callback. No sabemos si la discriminación se atenúa o se intensifica en etapas posteriores.
- **Autoselección:** si aplicantes minoritarios se autoseleccionan hacia empleos donde saben que serán bien recibidos, el sample average puede subestimar la discriminación marginal.
- **Sectores estudiados:** entry-level; no sabemos si el patrón se sostiene en puestos ejecutivos.
- **Contexto temporal:** 2001-2002; el mercado laboral y las normas anti-discriminatorias han cambiado desde entonces.

Consideraciones éticas

- **Engaño:** 1,300 empresas dedicaron tiempo a evaluar aplicaciones falsas.
- El IRB aprobó el estudio bajo la lógica del beneficio público y daño marginal.
- Ninguna oferta se aceptó; el daño total fue del orden de minutos por aviso.
- Bertrand y Mullainathan discuten el punto explícitamente en el paper.
- Debate abierto: ¿se puede seguir haciendo este método bajo GDPR en Europa? Actualmente hay controversia.

Qué nos llevamos al resto del curso

- Un **template de diseño** listo para adaptar: aleatorizar nombre (o cualquier señal identitaria), enviar CVs, medir callback.
- Una **convención estadística** clara: reportar brechas absolutas y relativas, con SE clusterizados por aviso.
- Un **marco interpretativo**: el efecto medido no distingue taste-based de statistical; discutir ambos mecanismos.
- Un **estándar de rigor ético**: aprobar por comité, minimizar daño, publicar solo resultados agregados.
- Una **base para adaptación peruana**: Galarza y Yamada (2014) prueban que el método aterriza en el contexto local.

Puntos de discusión para la clase

- 1 El paper es de 2004. ¿Cuántas cosas del mercado laboral han cambiado desde entonces que podrían atenuar o intensificar la brecha?
- 2 Si vas a replicar el diseño en Perú, ¿qué señal identitaria elegirías: apellido andino/europeo, foto, distrito de residencia?
- 3 Bertrand-Mullainathan encuentran que subir la calidad del CV no reduce la brecha. ¿Qué implicancias tiene para políticas como .ªfirmative action.º programas de capacitación?
- 4 ¿Es éticamente aceptable enviar 1,300 aplicaciones falsas a empresas reales? ¿Dónde pondrías el límite?
- 5 El paper no distingue taste-based de statistical. ¿Importa esa distinción para el diseño de políticas públicas?

Discusión abierta.

Cierre del bloque III: pasamos a la sesión práctica (PC2).