

Statistical analysis of list experiments

Blair y Imai (2012) Discusión de lectura

José Antonio Mendoza Sánchez

Curso 1INT46 Bloque III Facultad de Ciencias Sociales PUCP

Semestre 2026-2

Sobre esta discusión

- Comentamos Blair, G. y Imai, K. (2012). *Statistical analysis of list experiments*. *Political Analysis*, 20(1), 47-77.
- Es el paper fundacional para el análisis moderno de list experiments.
- Combina teoría estadística, tests de diagnóstico y software listo para usar.
- Es el paper que usó el paquete de R `list`, que aparece en la sesión práctica de hoy.

- 1 Contexto y motivación
- 2 Modelo estadístico
- 3 Diagnósticos: ceiling y floor
- 4 Tamaño de muestra y poder
- 5 Aplicación empírica del paper
- 6 Software y recomendaciones
- 7 Qué nos llevamos

Los autores

- **Graeme Blair:** en 2012 en el Department of Politics de Princeton University. Actualmente en UCLA. Especialista en encuestas sensibles y trabajo en contextos de conflicto.
- **Kosuke Imai:** politologo y estadístico. En 2012 en Princeton, actualmente en Harvard. Autor de varios paquetes de R (`Matching`, `list`, `mediation`, `endorse`) que la comunidad usa a diario.
- Combinan agenda empírica con desarrollo metodológico; el paper de 2012 sale de esa colaboración en Princeton.

Por qué este paper importa

- Antes de este paper, la mayoría de aplicaciones usaba solo la diferencia de medias, aunque existían antecedentes de estimadores de máxima verosimilitud (Corstange 2009, Glynn 2010, Imai 2011).
- Blair e Imai unifican y extienden esos enfoques con:
 - Estimadores multivariados eficientes con covariables.
 - Tests formales para detectar violaciones del *no design effect*.
 - Correcciones por ceiling y floor effects.
 - Software abierto (`list` en CRAN).
- Es el paper que estandariza la práctica moderna de análisis de list experiments.

El problema que resuelve

Con la aritmética básica solo se puede decir:

$$\hat{\pi} = \bar{Y}_{T=1} - \bar{Y}_{T=0}$$

Es un promedio simple. No dice nada sobre:

- Cómo cambia la prevalencia con el ingreso, la educación, la región.
- Si el diseño se rompió por ceiling o floor.
- Si algunos respondientes mintieron sistemáticamente.
- Cuántos respondientes se necesitan para detectar un efecto pequeño.

El paper responde a las cuatro preguntas.

Notación

- Y_i : número total de ítems que el respondiente i reporta.
- $T_i \in \{0, 1\}$: brazo (control o tratamiento).
- Z_i^* : variable latente. Vale 1 si al respondiente le aplica el ítem sensible, 0 si no.
- $Y_i^{(0)}$: número de ítems no sensibles que aplican. Nunca se observa directamente.

Modelo:

$$Y_i = Y_i^{(0)} + T_i \cdot Z_i^*$$

Solo se observa Y_i ; no se puede distinguir si el aumento vino del ítem sensible o del ruido.

Regresión con covariables

Modelan la probabilidad del ítem sensible como función de covariables X_i :

$$\Pr(Z_i^* = 1 \mid X_i) = f(X_i^\top \beta)$$

- f suele ser logística.
- β dice cómo la prevalencia varía con características del respondiente.
- Modelo similar para $Y_i^{(0)}$.
- Ambos se estiman simultáneamente por máxima verosimilitud.
- El paquete `list` implementa el estimador (`ictreg`).

Ventaja de estimar con covariables

- Reducción de varianza: intervalos más apretados con el mismo tamaño de muestra.
- Heterogeneidad: se puede reportar prevalencia por subgrupo (por ejemplo, hombres vs mujeres, urbano vs rural).
- Interacciones: se puede testear si un factor moderador aumenta o reduce la prevalencia del ítem sensible.
- Diagnóstico: si los coeficientes tienen signos raros, es señal de problema con el diseño.

Estimador bayesiano

- Blair e Imai proponen también una versión bayesiana con priors debilmente informativos.
- Útil cuando la muestra es pequeña o la prevalencia es cerca de los límites (0 o 1).
- Los intervalos de credibilidad son más robustos que los intervalos de confianza frecuentistas cuando el modelo está mal identificado.
- Implementado en `ictregBayes`.

Ceiling effects

- **Ceiling:** cuando todos los ítems no sensibles aplican al respondiente.
- En el brazo tratamiento, reportar $Y = J$ (máximo control) delata que el ítem sensible NO le aplica; reportar $Y = J + 1$ delata que Sí le aplica.
- El respondiente que quiere ocultar el sensible responderá $Y = J$, no $J + 1$.
- Esto sesga la prevalencia estimada hacia abajo.
- Blair e Imai proponen un test estadístico basado en la distribución de Y en el brazo tratamiento.

Floor effects

- **Floor:** cuando ningún ítem no sensible aplica al respondiente.
- En el brazo tratamiento, reportar $Y = 0$ delata que el sensible tampoco le aplica; reportar $Y = 1$ delata que Sí le aplica.
- El respondiente que quiere ocultar el sensible responderá $Y = 0$.
- Nuevamente sesga la estimación hacia abajo.
- Blair e Imai proponen tests y correcciones para floor también.

Corrección por ceiling y floor

El paper propone dos estrategias:

- 1 **Modelo estadístico corregido**: incorpora explícitamente la probabilidad de que un respondiente en ceiling o floor mienta. Requiere supuestos.
- 2 **Diseño revisado**: elegir ítems para minimizar la probabilidad de ceiling y floor.
 - Mezclar ítems muy comunes con ítems muy raros.
 - Usar $J \geq 4$ ítems no sensibles.
 - Piloto para verificar la distribución de Y en control.

Cómo dimensionar la muestra

Blair e Imai derivan fórmulas para el tamaño de muestra necesario:

- Depende de la prevalencia esperada (π).
- Depende de la varianza de Y en el brazo control (σ_0^2).
- Depende del nivel de significancia (α) y potencia ($1 - \beta$).
- Fórmula aproximada por brazo:

$$n \approx \frac{2\sigma_0^2(z_{1-\alpha/2} + z_{1-\beta})^2}{\pi^2(1 - \pi)}$$

Consecuencias prácticas para el n

De la fórmula anterior se sigue que:

- Cuando la prevalencia π es baja, n crece rápidamente (el denominador $\pi^2(1 - \pi)$ tiende a cero).
- Un list experiment es una herramienta *ineficiente* respecto a la pregunta directa (el estimador tiene mucha más varianza); solo vale la pena cuando la pregunta directa produce sesgo grande.
- Blair e Imai muestran que el error estándar típico del list experiment puede ser 5 a 10 veces mayor que el de la pregunta directa con la misma muestra.
- Recomendación: si esperas prevalencia menor a 5 % o dispones de menos de 500 casos por brazo, considera diseños alternativos.

Potencia por subgrupos

- Estimar por subgrupo (por ejemplo, prevalencia por región) requiere aproximadamente el mismo n dentro de cada subgrupo.
- Con 5 regiones, el n total se multiplica por 5.
- En la práctica, diseñar para heterogeneidad requiere muestras ~ 3000 - 5000 total.
- Los proyectos grupales del curso no llegarán a esos tamaños: se debe declarar la limitación de poder al reportar.

El caso empírico del paper

Blair e Imai aplican su metodología a dos datasets sobre prejuicio racial en EE.UU.:

- **1991 National Race and Politics Survey** (Sniderman, Tetlock y Piazza 1992): el primer list experiment publicado en ciencia política. Ítem sensible: “a black family moving next door to you.” Items de control: impuesto a la gasolina, salarios de deportistas, corporaciones contaminantes.
- **1994 Multi-Investigator Survey**: incluye un list experiment sobre affirmative action, permite comparar respuestas directas vs. indirectas.
- Los autores muestran que el modelo con covariables revela heterogeneidad que la aritmética simple no capta.
- Los tests que proponen detectan efectos de diseño que pasarían desapercibidos.

Hallazgo metodológico central

Al aplicar el modelo con covariables a datos reales:

- La prevalencia agregada da una lectura promedio.
- El modelo con covariables revela variaciones grandes por subgrupo.
- El detalle regional o demográfico era invisible en la aritmética simple.
- Los tests de diseño detectan problemas en algunos subgrupos que pasarían desapercibidos con el estimador ingenuo.
- Es una muestra de por qué el modelo formal aporta: no solo confirma, refina.

El paquete list

Funciones principales del paquete de R:

- `ictreg(y ~ x, treat = "T", J = 4, data = df)`: estimación ML con covariables.
- `ictregBayes(...)`: versión bayesiana.
- `ictSample(pi, sigma, alpha, beta)`: cálculo de n requerido.
- `ictHypothesis(...)`: tests de diseño.
- `combinedListDirect(y ~ x, direct, data)`: combina list experiment con pregunta directa.

Todo esto se cubre en la sesión práctica de hoy (PD2).

Recomendaciones prácticas del paper

Blair e Imai cierran con recomendaciones que hoy son estándar:

- 1 Pilotar el instrumento antes de escalar.
- 2 Usar $J \geq 4$ ítems no sensibles.
- 3 Incluir tanto ítems comunes como raros para evitar ceiling / floor.
- 4 Preguntar directamente el mismo ítem a otro brazo, para comparar.
- 5 Reportar prevalencia agregada, por subgrupos, y con tests de diagnóstico.
- 6 Pre-registrar el análisis.

Qué llevamos al resto del curso

- La **aritmética básica** de list experiments es solo el punto de partida.
- Modelos con covariables permiten mucho más: heterogeneidad, tests de diseño, potencia.
- Los ceiling y floor effects son la amenaza principal; hay que diseñarlos para evitarlos.
- El paquete `list` de R hace el análisis accesible sin escribir el modelo desde cero.
- Estas ideas se generalizan: aparecen conceptos parecidos en el bloque VI (conjoint) y VII (mixed logit).

Puntos de discusión para la clase

- 1 ¿En qué tema peruano usarías un list experiment mañana?
- 2 Los list experiments requieren muestras grandes. ¿Cómo balancearías eso con presupuesto limitado en un proyecto de tesis?
- 3 Si hubiera pregunta directa y list experiment en la misma encuesta, y dieran resultados muy distintos, ¿cuál reportarías? ¿Ambas?
- 4 Los ceiling effects sesgan hacia abajo. ¿Se te ocurre un diseño alternativo que los evite completamente?

Discusión abierta.

Pasamos a la PD2: análisis de un list experiment simulado.