

Discussion de paper: Chrzan y Peitz (2019)

Best-Worst Scaling with Many Items

Curso 1INT46. Bloque V. Semana 11

Chrzan, K. & Peitz, M. (2019). *Best-worst scaling with many items.* **Journal of Choice Modelling**, 30, 61-72.

- Autores: Keith Chrzan y Megan Peitz, ambos en **Sawtooth Software**, Inc.
- Publicado en JOCM (Elsevier), recibido agosto 2017, aceptado enero 2019.
- Compara metodologicamente dos aproximaciones para hacer BWS cuando hay muchos items: *Sparse BWS* y *Express BWS*.
- Perspectiva: practitioners de marketing research que ejecutan estudios BWS reales con clientes corporativos.

Problema que motiva el paper

BWS clasico funciona bien con listas relativamente cortas (5 a 20 items). Pero:

- Los practitioners suelen recibir pedidos con listas mucho mas largas.
- Chrzan y Peitz reportan que un tercio de los estudios de sus clientes en el ultimo ano involucraron 30 items o mas.
- Casi 1 en 10 involucraron 50+ items.
- Un cliente hacia varios estudios al mes con 100+ items cada uno.

Pregunta: ?Como se hace BWS con 30, 50 o 100 items sin agotar al respondiente?

Contribucion principal

El paper:

- 1 Repite las comparaciones previas de Sparse BWS vs Express BWS usando datos empiricos nuevos (no simulados).
- 2 Extiende hallazgos previos: usa suficientes observaciones por respondiente para poder reproducir un *Full BWS* como benchmark.
- 3 Confirma que Sparse BWS reproduce mejor las utilidades “verdaderas” del Full BWS que Express BWS.
- 4 Ofrece recomendaciones concretas de diseno para practitioners con listas de muchos items.

- **Case 1 (object case):** items son objetos discretos. Finn y Louviere (1992). **Este paper trata solo Case 1.**
- **Case 2 (profile case):** perfiles multiatributo, se elige mejor/peor atributo.
- **Case 3 (multi-profile case):** varios perfiles, se elige mejor/peor perfil.

El problema de “muchos items” aparece especialmente en Case 1: cuando el investigador quiere jerarquizar un catalogo grande de opciones.

Full BWS clasico como benchmark

Estructura:

- Cada respondiente ve todos los items en varias tareas.
- Cada item aparece un numero fijo de veces (usualmente 3).
- Diseno: BIBD o busqueda computacional (Kuhfeld y Wurst 2012).
- Analisis: BW scores (Louviere et al. 2015), MNL agregado (McFadden 1974), latent class MNL (DeSarbo et al. 1995), Hierarchical Bayes (Allenby y Ginter 1995).

Con 36 items y $k = 4$ por choice set, cada respondiente contesta 27 preguntas. Con 100 items eso se multiplica por 3, dando 75+ preguntas: cognitivamente inviable.

Solucion 1: Express BWS (Wirth y Wolfrath 2012)

- Cada respondiente ve un *subconjunto* aleatorio de items.
- Dentro de su subconjunto, cada item aparece 3 o 4 veces.
- Cada respondiente ve solo una parte del universo de items.
- Los items se comparan indirectamente via el sample de respondientes.

Ejemplo: con 100 items, cada respondiente ve 24 items en 18 preguntas de 4 items. No ve los otros 76 items.

Solucion 2: Sparse BWS (Wirth y Wolfrath 2012)

- Cada respondiente ve *todos* los items del universo.
- Pero cada item aparece *una sola vez* en el questionnaire del respondiente.
- Al variar el orden y las combinaciones entre respondientes, se recupera la informacion en agregado.

Ejemplo: con 100 items y $k = 5$ por choice set, un respondiente contesta 20 preguntas cubriendo los 100 items una sola vez.

Estudios previos comparando Sparse y Express

- **Wirth y Wolfrath (2012)**: Sparse ligeramente mejor que Express para predecir holdout choices.
- **Chrzan (2015)**: dos estudios artificiales; correlacion sample-level de 0.995 (Sparse) vs 0.989 (Express); diferencia significativa pero pequena.
- **Serpetti et al. (2016)**: en un human study de 2,202 respondientes, correlacion in-sample de 0.49 (Sparse) vs 0.41 (Express); MAE out-of-sample 0.034 (Sparse) vs 0.038 (Express).

Los tres coinciden en que Sparse es mejor. Chrzan y Peitz (2019) buscan confirmar esto con un diseno mas riguroso.

Encuesta a 1,207 clientes de restaurantes casual dining sobre preferencias por 36 postres.

- Aleatorizacion a uno de tres tratamientos:
 - ▶ Full BWS ($n = 403$).
 - ▶ Sparse BWS ($n = 400$).
 - ▶ Express BWS ($n = 404$).
- Cada tratamiento tiene el mismo tamano de muestra.
- El Full BWS actua como **benchmark**: sus utilidades individuales se toman como “verdaderas”.

Comparacion de disenos

Caracteristica	Full BWS	Sparse BWS	Express BWS
Choice sets por respondiente	27	9	9
Items por choice set	4	4	4
Items vistos por respondiente	36	36	12
Veces que cada item se ve	3	1	3
N respondientes	403	400	404

Sparse y Express tienen la misma carga cognitiva (9 preguntas). Difieren en *como* distribuyen la exposicion: Sparse cubre todos los items una vez; Express cubre un subset varias veces.

Hallazgos principales

Los autores encuentran:

- **Sparse BWS** reproduce mejor las utilidades del Full BWS a nivel individual.
- **Express BWS** pierde precision porque cada respondiente ve solo un subset.
- En correlaciones agregadas la diferencia es chica, pero en utilidades individuales es sustantiva.
- La diferencia es especialmente importante para aplicaciones que requieren utilidades a nivel de respondiente: factor analysis, cluster analysis, TURF (Total Unduplicated Reach and Frequency).

Por que Sparse es mejor

- Sparse permite a cada respondiente “pesar” cada item personalmente al menos una vez.
- Express deja items sin evaluar por cada respondiente, generando missing at random (bajo el diseno) pero sin informacion individual.
- Con HB (Hierarchical Bayes), Sparse aprovecha mejor la informacion agregada para inferir preferencias individuales.
- Express requiere mas dependencia del prior en HB, lo que reduce la precision individual.

Del paper se derivan pautas concretas:

- Para 20-30 items: usar Full BWS estandar.
- Para 30-50 items: *considerar Sparse BWS*.
- Para 50+ items: *Sparse BWS es preferible*. Express solo si el objetivo es exclusivamente sample-level (agregado).
- Para 100+ items: Sparse BWS con HB en analisis.
- Siempre incluir un piloto para verificar la carga cognitiva y el tiempo de respuesta.

Limitaciones del estudio

- El estudio empirico usa 36 items; conclusiones para 100+ items son extrapolaciones.
- Solo compara Sparse y Express; no incluye otras alternativas como Bayesian efficient designs para BWS.
- El contexto (postres) es familiar; con items menos comunes la fatiga podria diferir.
- Se enfoca en Case 1 (object case); no aborda Case 2 o Case 3.

- Consolida el uso de Sparse BWS como metodo preferido para many items.
- Provee benchmark empirico solido para replicaciones futuras.
- Es un paper de referencia para practitioners que reciben pedidos con listas largas.
- Confirma que la aleatorizacion en el diseno importa: no todo diseno con misma carga cognitiva produce el mismo resultado.

Preguntas para la discusion

- 1 ?En que casos peruanos vale la pena hacer BWS con 30+ items?
- 2 ?Es realista para un estudiante de tesis manejar Sparse BWS o mejor limitarse a Full BWS con menos items?
- 3 ?La ventaja de Sparse sobre Express justifica la complejidad adicional del diseno?
- 4 ?Como comparariamos Chrzan-Peitz con una alternativa como Q-sort para listas largas?
- 5 ?Cuando reportas resultados de un BWS con muchos items, como comunicas la incertidumbre individual?

- Si en tu proyecto necesitas 20+ items, considera desde el inicio la carga cognitiva.
- Sparse BWS es una opcion viable si necesitas jerarquizar muchos items sin agotar respondientes.
- Reporta explicitamente el diseno usado (Full, Sparse o Express) en tu documentacion.
- Al analizar, usa HB si el objetivo es individualizar; MNL agregado es suficiente si el interes es sample-level.
- Para el TG2 o proyectos aplicados: entre 8 y 20 items sigue siendo el sweet spot recomendado.